

A Deep Learning Model Based on Visual Representation Oriented Toward Reducing the Evasion Rate of Zero-Day Threats in Intrusion Detection Systems for Enterprise Networks, 2026

L. J. Villegas^{1,*}, E. A. Espinoza¹, Y. O. Tello¹

¹ National University of Engineering, Lima,
Peru

luis.villegas.n@uni.pe, emerson.espinoza.s@uni.pe, yury.tello.c@uni.edu.pe

Un modelo de aprendizaje profundo basado en representación visual orientado a reducir la tasa de evasión de amenazas de día cero en sistemas de detección de intrusiones para redes empresariales, 2026

Abstract. Deep learning-based intrusion detection systems commonly operate under a closed-set assumption, which may cause previously unseen threats to be assigned to known categories. This study proposes OSR-ViT, an architecture that integrates packet-based visual learning and open-set recognition for zero-day threat detection in enterprise network traffic. The model transforms the first seven packets of each session into an RGB-E multichannel representation processed by a *Vision Transformer*. The resulting latent representation is evaluated through class-specific Mahalanobis profiles and rejection thresholds to distinguish known traffic from out-of-distribution samples. Experiments on CSE-CIC-IDS2018 considered Benign, DoS, and DDoS as known classes, while Botnet and Web_Attack were reserved as OOD traffic. In closed-set classification, OSR-ViT achieved an Accuracy of 0.9995, a Macro F1 of 0.9989, and an MCC of 0.9986. In the open-set evaluation, under the selected operating point, it obtained an AUROC of 0.8280, an AUPR of 0.7474, an OOD recall of 0.6836, an OOD F1 of 0.7511, and a known-class false rejection rate of 0.1933. Taken together, these results show high discrimination within the known domain and indicate that open-set deployment requires an explicit operating-point calibration to balance OOD sensitivity and known-traffic preservation.

Keywords. Intrusion detection systems, zero-day threats, open-set recognition, Vision Transformer, out-of-distribution detection, network traffic representation.

Abstract. Los sistemas de detección de intrusiones basados en aprendizaje profundo suelen operar bajo una suposición de mundo cerrado, lo que puede provocar que amenazas no observadas sean asignadas a categorías conocidas. Este estudio propone OSR-ViT, una arquitectura que integra aprendizaje visual basado en paquetes y reconocimiento de conjunto abierto para detectar amenazas de día cero en tráfico de redes empresariales. El modelo transforma los primeros siete paquetes de cada sesión en una representación multicanal RGB-E procesada mediante un *Vision Transformer*. La representación latente resultante se evalúa mediante perfiles de Mahalanobis específicos por clase y umbrales de rechazo para distinguir tráfico conocido de muestras fuera de distribución. Los experimentos sobre CSE-CIC-IDS2018 consideraron Benign, DoS y DDoS como clases conocidas, mientras que Botnet y Web_Attack se reservaron como tráfico OOD. En clasificación *closed-set*, OSR-ViT alcanzó una Accuracy de 0,9995, un Macro F1 de 0,9989 y un MCC de 0,9986. En la evaluación *open-set*, bajo el punto operativo seleccionado, obtuvo un AUROC de 0,8280, un AUPR de 0,7474, un *recall* OOD de 0,6836, un F1 OOD de 0,7511 y una tasa de falso rechazo de clases conocidas de 0,1933. En conjunto, los resultados muestran una alta discriminación dentro del dominio conocido e indican que el despliegue en conjunto abierto requiere una calibración explícita del punto operativo para equilibrar la sensibilidad OOD y la preservación del tráfico conocido.

Keywords. Sistemas de detección de intrusiones, amenazas de día cero, reconocimiento de conjunto abierto, Vision Transformer, detección fuera de distribución, representación del tráfico de red.

1. Introducción

La adopción de infraestructuras de computación en la nube y la evolución de las redes empresariales han modificado la provisión de servicios informáticos y ampliado la superficie de exposición frente a amenazas cibernéticas complejas [4]. En este entorno dinámico, los sistemas de detección de intrusiones (IDS) basados exclusivamente en firmas estáticas y reglas predefinidas presentan limitaciones para identificar ataques polimórficos o de día cero [12]. Como respuesta, el aprendizaje profundo se ha incorporado al diseño de arquitecturas IDS modernas debido a su capacidad para aprender representaciones y dependencias jerárquicas a partir del tráfico de red [4]. Sin embargo, estos modelos continúan requiriendo procedimientos de entrenamiento, actualización y adaptación ante cambios en la distribución del tráfico.

Una limitación relevante de muchos modelos supervisados de aprendizaje profundo proviene de la suposición de mundo cerrado (*closed-set*), según la cual las clases presentes durante la evaluación corresponden a categorías observadas durante el entrenamiento [20]. Bajo esta formulación, los clasificadores basados en Softmax asignan cada entrada a una de las clases conocidas y pueden producir puntuaciones de confianza elevadas ante instancias anómalas o fuera de distribución [16]. En consecuencia, una amenaza no observada durante el entrenamiento puede ser asignada incorrectamente a una categoría conocida, reduciendo la capacidad del IDS para distinguir ataques potencialmente desconocidos [3].

Para abordar este problema, la literatura ha explorado enfoques de modelado probabilístico y cuantificación de incertidumbre, como *Monte Carlo Dropout* [18] y las redes neuronales bayesianas [16]. Aunque estas técnicas permiten estimar la incertidumbre predictiva, algunas configuraciones requieren múltiples inferencias o procedimientos

probabilísticos adicionales que pueden incrementar el costo computacional. Paralelamente, arquitecturas de visión artificial como los *Vision Transformers* (ViT) han sido adaptadas al análisis de tráfico mediante representaciones visuales [21, 13]. No obstante, varias de estas propuestas mantienen una formulación de clasificación cerrada y no incorporan una regla explícita para rechazar muestras fuera de la distribución [9].

En este contexto, el presente artículo propone OSR-ViT, una arquitectura orientada a la detección de amenazas no observadas en sistemas de detección de intrusiones. El enfoque representa los primeros paquetes de cada sesión mediante un tensor multicanal RGB-E, que es procesado por un *Vision Transformer* para aprender representaciones discriminativas de las clases conocidas. Posteriormente, el embedding latente obtenido se integra con un mecanismo de reconocimiento de conjunto abierto basado en distancias de Mahalanobis y umbrales robustos específicos por clase. De este modo, el sistema puede clasificar las muestras pertenecientes al dominio supervisado y rechazar como OOD aquellas que se alejan de los perfiles latentes conocidos.

Las principales contribuciones de este estudio son las siguientes:

- Se introduce una representación multicanal RGB-E construida directamente a partir de los primeros paquetes de cada sesión, que integra información direccional, temporal y de entropía sin depender exclusivamente de características estadísticas preextraídas.
- Se incorpora una regularización progresiva de Fisher sobre el token *CLS* del *Vision Transformer*, orientada a favorecer la compactación intra-clase y la separación inter-clase del espacio latente utilizado posteriormente por el módulo OSR.
- Se define un mecanismo de reconocimiento de conjunto abierto basado en distancia de Mahalanobis y umbrales robustos específicos por clase, calibrados únicamente con muestras conocidas de validación. El protocolo experimental permite analizar conjuntamente la detección OOD y el falso rechazo introducido sobre el dominio conocido.

El resto del artículo está organizado de la siguiente manera. La Sección 2 revisa trabajos previos y sus limitaciones. La Sección 3 describe la metodología propuesta, mientras que la Sección 4 detalla el diseño experimental. La Sección 5 presenta los resultados y su discusión. Finalmente, la Sección 6 expone las conclusiones y las líneas de trabajo futuro.

2. Trabajos previos

La representación visual del tráfico de red ha sido explorada como una estrategia para aprovechar la capacidad de extracción espacial de los modelos de visión profunda. Ghadermazi et al. propusieron SPIN-IDS, un enfoque que transforma secuencias de hasta 15 paquetes pertenecientes a una comunicación en representaciones multicanal, donde los paquetes enviados en sentido directo e inverso se asignan a canales diferenciados [7]. A partir de estas imágenes, una CNN realiza clasificación binaria entre tráfico benigno y malicioso sin esperar necesariamente la finalización completa del flujo. El modelo alcanzó un Recall de 98.77 % al utilizar los primeros nueve paquetes de cada secuencia. No obstante, su protocolo experimental corresponde a un escenario *closed-set*; las clases Botnet, Web Attack-XSS y SQL Injection fueron excluidas debido a su reducido número de muestras y no se utilizaron como amenazas desconocidas para evaluar un mecanismo de rechazo.

Otros trabajos han utilizado características tabulares agregadas para construir imágenes compatibles con arquitecturas Vision Transformer. Ho et al. seleccionaron 24 características de flujo mediante ganancia de información y las transformaron en imágenes RGB de $24 \times 24 \times 3$, posteriormente clasificadas mediante un ViT [9]. El método fue evaluado sobre CIC-IDS2017 y UNSW-NB15, alcanzando exactitudes de 98.5 % y 96.3 %, respectivamente, en clasificación binaria. De forma complementaria, He et al. reorganizaron vectores de 64 características como matrices de 8×8 y propusieron DE-ViT, una variante que incorpora convolución y atención deformables para adaptar la extracción de características a regiones relevantes de la entrada [8]. Aunque ambos

enfoques muestran la utilidad de los Transformers visuales para clasificación binaria y multiclase, sus capas de salida asignan cada muestra a una de las categorías conocidas y no incorporan una decisión explícita de rechazo ante entradas fuera de distribución.

Frente a esta limitación, diversos trabajos han abordado directamente la detección de ataques desconocidos mediante reconocimiento de conjunto abierto y análisis del espacio latente. Zhang et al. propusieron una red de clasificación abierta que excluye categorías completas durante el entrenamiento y las utiliza posteriormente como ataques desconocidos [20]. Su arquitectura reemplaza la decisión Softmax convencional por un clasificador basado en el centro medio de cada clase conocida. Una muestra se rechaza cuando su distancia euclidiana al centro más cercano supera el umbral correspondiente. Además, el espacio latente se optimiza mediante una combinación de pérdidas Cross-Entropy, Fisher y Maximum Mean Discrepancy. En CICIDS2017, el método alcanzó un AUROC promedio de 0.938 para la detección de ataques desconocidos. Sin embargo, el artículo no especifica de manera inequívoca si los umbrales de aceptación se calibran mediante una partición de validación independiente.

La incertidumbre predictiva constituye otra alternativa para identificar muestras fuera de distribución. Talpini et al. presentaron UC-BNN, una red neuronal bayesiana que combina incertidumbre epistémica con un modelo gaussiano multivariante ajustado sobre la representación latente [16]. El método retiene familias completas como desconocidas en distintos escenarios experimentales y utiliza la distancia de Mahalanobis para corregir la incertidumbre asignada a cada muestra. En este caso, el umbral se obtiene mediante el percentil 99.5 de las distancias calculadas sobre un conjunto de validación, lo que establece una separación explícita entre ajuste y evaluación. El desempeño OOD se analiza mediante AUROC y AUROC20, aunque el cálculo de la distancia requiere invertir una matriz de covarianza, lo que incrementa su costo cuando aumenta la dimensionalidad del espacio latente.

Park y Lim propusieron posteriormente un marco híbrido de múltiples etapas que combina

agrupamiento K-means, un Autoencoder Variacional y una red neuronal profunda para detectar ataques conocidos y Zero-Day [14]. En cada escenario experimental se excluye una familia completa del entrenamiento y se reserva para la prueba. La detección de amenazas no vistas se realiza mediante la distancia de Mahalanobis entre la representación latente producida por el VAE y el vector medio aprendido, aplicando un umbral robusto basado en la desviación absoluta de la mediana. El estudio muestra que el procedimiento puede alcanzar sensibilidades elevadas en determinadas familias, pero también evidencia una degradación considerable cuando las distribuciones latentes de los ataques desconocidos se superponen con el tráfico benigno.

En conjunto, los trabajos revisados muestran avances en la representación visual del tráfico, la aplicación de Vision Transformers a la clasificación de intrusiones y el diseño de mecanismos latentes para detectar ataques desconocidos. Sin embargo, los enfoques visuales basados en ViT se concentran principalmente en escenarios *closed-set*, mientras que los métodos de reconocimiento abierto suelen operar sobre características tabulares agregadas o representaciones producidas por autoencoders. Asimismo, no todos los estudios separan la calibración del umbral de la evaluación final ni cuantifican explícitamente el falso rechazo inducido sobre las clases conocidas. En consecuencia, permanece abierta la necesidad de estudiar arquitecturas que integren aprendizaje visual a partir de paquetes y una regla explícita de rechazo, bajo un protocolo que diferencie calibración y prueba.

3. Enfoque propuesto

3.1. Descripción general y formulación del problema

Sea

$$\mathcal{D}_K = \{(x_i, y_i)\}_{i=1}^n, \quad y_i \in \mathcal{Y}_K = \{1, \dots, K\}, \quad (1)$$

el conjunto de entrenamiento compuesto exclusivamente por clases conocidas. Cada entrada x_i

corresponde a un tensor RGB-E de dimensión

$$x_i \in \mathbb{R}^{N_{\min} \times 144 \times 3}, \quad (2)$$

donde RGB-E denota una representación multicanal en la que los dos primeros canales codifican los sentidos *forward* y *backward* de la comunicación, mientras que el tercer canal incorpora la entropía del paquete. El tensor se construye a partir de los primeros paquetes de una sesión de red; su procedimiento de generación se describe en la subsección siguiente. El clasificador supervisado debe aprender una función

$$h_\theta : \mathcal{X} \longrightarrow \mathcal{Y}_K, \quad (3)$$

orientada a discriminar las categorías pertenecientes al dominio conocido.

Durante la inferencia abierta, una muestra x puede pertenecer a alguna clase de $\mathcal{Y}_K$ o a una categoría no observada durante el entrenamiento. Por tanto, la función de decisión final se define como

$$g : \mathcal{X} \longrightarrow \mathcal{Y}_K \cup \{\text{OOD}\}. \quad (4)$$

La salida $g(x)$ conserva la clasificación de las muestras compatibles con los perfiles conocidos y asigna la etiqueta OOD cuando la representación latente se sitúa fuera de sus fronteras de aceptación.

Para abordar ambas tareas, OSR-ViT se organiza en tres etapas: generación de la representación RGB-E, aprendizaje supervisado y regularización del espacio latente mediante un Vision Transformer, y reconocimiento abierto basado en distancias geométricas y umbrales robustos por clase. Las subsecciones siguientes describen cada componente del proceso.

3.2. Generación adaptativa de tensores espacio-semánticos

La primera etapa del proceso transforma capturas PCAP en tensores tridimensionales compatibles con la arquitectura de visión utilizada posteriormente. Para cada captura lógica, los paquetes IPv4 o IPv6 con transporte TCP o UDP se agrupan por una tupla canónica de flujo, y cada sesión se finaliza por cierre TCP mediante banderas FIN/RST, por expiración de inactividad o

al finalizar la captura. A partir del primer paquete observado de cada sesión, el sistema aplica un umbral de retención denotado como $N_{\min}$. Para garantizar una forma de entrada fija sin recurrir al relleno sintético en la dimensión temporal, las sesiones que caducan acumulando menos de $N_{\min}$ paquetes son descartadas sistemáticamente. Por el contrario, las comunicaciones que superan este umbral son truncadas de manera estricta a sus primeros $N_{\min}$ paquetes. Esta estrategia permite preservar información temprana de la comunicación, incluyendo campos de cabecera presentes en los bytes serializados del paquete, aunque no presupone que todas las sesiones contengan necesariamente el establecimiento TCP completo.

Cada instancia se codifica en un tensor de dimensiones $[N_{\min}, 144, 3]$. Se adopta la denominación RGB-E (Red, Green, Blue - Entropy) por analogía estructural con las imágenes a color estándar empleadas en arquitecturas de visión artificial ($H \times W \times C$), reasignando funcionalmente los tres canales visuales para alojar características de red. La construcción del tensor sigue reglas de mapeo estrictas para garantizar la reproducibilidad:

- **Estructura Espacial:** Cada fila representa uno de los paquetes secuenciales de la sesión. Las 144 columnas se dividen rígidamente: las primeras 16 columnas se reservan para la codificación del tiempo delta, y las 128 columnas restantes almacenan los bytes serializados de las cabeceras y la carga útil. Los paquetes con longitud inferior a 128 bytes se completan con relleno de ceros, mientras que aquellos que exceden este límite son truncados.
- **Filtrado por Longitud de Sesión y Relleno:** El tensor subyacente se inicializa completamente en ceros. Para evitar un sesgo por relleno sintético masivo, las sesiones que caducan o finalizan acumulando un número de paquetes estrictamente menor a $N_{\min}$ son descartadas.
- **Distribución de Canales:** El Canal 0 (análogo al Rojo) almacena exclusivamente los

paquetes del sentido *forward* (flujo iniciado por el emisor original). El Canal 1 (análogo al Verde) almacena los paquetes del sentido *backward* (respuesta). Cuando un paquete pertenece a un sentido específico, se mapea en su canal correspondiente, manteniendo el canal opuesto en cero para esa fila. El Canal 2 (análogo al Azul) se destina a la entropía (E), cuyo valor escalar se replica a lo largo de las 144 columnas de la fila. Esta característica resume el grado de variabilidad de los bytes de payload y puede complementar la información estructural en escenarios de tráfico heterogéneo; sin embargo, en este trabajo se utiliza como una característica auxiliar, no como un detector independiente de cifrado u ofuscación [11, 15].

- **Codificación Temporal y Entropía:** El tiempo delta (Δt) respecto al paquete anterior se recorta al tiempo máximo de expiración del flujo (*timeout*) y se somete a una transformación logarítmica escalada al rango continuo $[0, 255]$: $255 \times \frac{\ln(1+\Delta t)}{\ln(1+\text{timeout})}$. Este valor se repite en las 16 columnas temporales. Por su parte, la entropía de Shannon se calcula sobre la carga útil (*payload*) del paquete; si el paquete carece de carga útil, su entropía se define explícitamente como 0,0.

Para reducir la dependencia de identificadores ambientales, antes de serializar el paquete se sobrescriben las direcciones MAC e IP de origen y destino con valores nulos. De este modo, la representación conserva otros campos del paquete, pero evita que el modelo dependa directamente de direcciones específicas de la captura. Posteriormente, los tensores generados se validan y perfilan mediante un escalado Min-Max global. Para prevenir la fuga de datos, los límites mínimos y máximos de los canales direccionales, del tiempo delta, del bloque de bytes y de la entropía se calcularon exclusivamente sobre el subconjunto de entrenamiento (compuesto solo por clases conocidas), se aplicaron de manera invariable a las particiones de validación, prueba y fuera de distribución.

Finalmente, el desbalance de clases se aborda en esta etapa mediante reglas de retención

definidas por partición y etiqueta, en lugar de generar ejemplos sintéticos sobre el espacio crudo de los tensores. Esta decisión evita introducir muestras artificiales cuya validez semántica no pueda verificarse directamente a nivel de paquete o sesión. Por tanto, la etapa de ingesta no modifica la semántica del tráfico mediante interpolación, sino que produce instancias normalizables y auditables para el entrenamiento y la evaluación posteriores [12, 10, 4].

3.3. Procedimiento de Asignación de Etiquetas a Nivel de Sesión

La determinación de la etiqueta final de cada sesión sigue un procedimiento basado en el emparejamiento temporal y de red, diseñado para gestionar adecuadamente las comunicaciones que contienen tráfico mixto. El proceso de asignación se rige por las siguientes reglas:

- **Fuente de Verdad y Ventanas Horarias:** Se toma como referencia el cronograma oficial del conjunto de datos CSE-CIC-IDS2018, vinculando las direcciones IP de atacantes y víctimas con las ventanas temporales definidas para cada evento malicioso.
- **Alineación Temporal:** Las marcas de tiempo de las capturas PCAP se ajustan a la zona horaria AST (UTC-4) para asegurar la sincronización exacta con los registros de ataque del conjunto de datos.
- **Tratamiento Bidireccional:** El análisis abarca ambas direcciones del flujo. Se verifica de manera continua si el par de IPs (*IP_origen-IP_destino* o viceversa) coincide con una actividad de ataque reportada en ese instante específico.
- **Promoción de Etiquetas ante Tráfico Mixto:** Toda sesión se inicializa como *Benign*. Si durante su desarrollo se identifica al menos un paquete malicioso, se activa un criterio de ascenso basado en criticidad: el tráfico benigno representa el nivel base, seguido por los ataques del dominio supervisado, y finalmente las amenazas de conjunto abierto. La sesión hereda la etiqueta de

Algorithm 1 Construcción y etiquetado de sesiones RGB-E desde capturas PCAP

Entrada: Capturas PCAP $\mathcal{P}$, cronograma de ataques $\mathcal{A}$, ventana $N_{\min}$ y timeout T

Salida: Conjunto de sesiones etiquetadas $\mathcal{D} = \{(X_s, y_s)\}$

```

1:  $\mathcal{H} \leftarrow \emptyset$  ▷ Sesiones activas
2:  $\mathcal{D} \leftarrow \emptyset$ 
3: para cada paquete  $p \in \mathcal{P}$ , ordenado temporalmente hacer
4:    $t \leftarrow \text{timestamp}(p)$ 
5:    $\text{CerrarExpiradas}(\mathcal{H}, t, T, \mathcal{D})$ 
6:   si  $p$  no pertenece a un flujo TCP/UDP sobre IP entonces
7:     continuar
8:   fin si
9:    $k \leftarrow \text{TupleaCanonica}(p)$  ▷ Identificador bidireccional
10:   $d \leftarrow \text{ObtenerDireccion}(p, k)$ 
11:  si  $k \notin \mathcal{H}$  entonces
12:     $\mathcal{H}[k] \leftarrow \text{NuevaSesion}(k, t)$ 
13:  fin si
14:   $s \leftarrow \mathcal{H}[k]$ 
15:   $s.n \leftarrow s.n + 1$ 
16:   $s.t_{\text{ultimo}} \leftarrow t$ 
17:  si  $s.n \leq N_{\min}$  entonces
18:     $\text{AlmacenarPaquete}(s, p, d)$ 
19:  fin si
20:   $y_p \leftarrow \text{EtiquetarPaquete}(p, t, \mathcal{A})$ 
21:   $s.y \leftarrow \text{ActualizarEtiqueta}(s.y, y_p)$ 
22:  si  $p$  contiene una bandera TCP FIN o RST entonces
23:     $\text{FinalizarSesion}(s, N_{\min}, \mathcal{D})$ 
24:    eliminar  $k$  de  $\mathcal{H}$ 
25:  fin si
26: fin para
27: para cada sesión activa  $s \in \mathcal{H}$  hacer
28:    $\text{FinalizarSesion}(s, N_{\min}, \mathcal{D})$ 
29: fin para
30: retornar  $\mathcal{D}$ 

31: procedimiento  $\text{EtiquetarPaquete}(p, t, \mathcal{A})$ 
32:   si la fecha, el intervalo temporal y las direcciones de  $p$  coinciden con un evento de  $\mathcal{A}$  entonces
33:     retornar etiqueta del evento
34:   si no
35:     retornar BENIGN
36:   fin si
37: fin procedimiento

38: procedimiento  $\text{FinalizarSesion}(s, N_{\min}, \mathcal{D})$ 
39:   si  $s.n < N_{\min}$  entonces
40:     retornar ▷ Descartar sesión incompleta
41:   fin si
42:    $P_s \leftarrow \text{Anonimizar}(s.\text{paquetes})$ 
43:    $X_s \leftarrow \text{ConstruirRGBE}(P_s[1:N_{\min}])$ 
44:    $\mathcal{D} \leftarrow \mathcal{D} \cup \{(X_s, s.y)\}$ 
45: fin procedimiento

```

mayor prioridad observada, evitando que la actividad anómala quede oculta por ráfagas de paquetes legítimos dentro de la misma conexión.

3.4. Arquitectura Vision Transformer (ViT)

El núcleo de la arquitectura propuesta se basa en el paradigma Vision Transformer (ViT), que adapta el mecanismo de autoatención al

procesamiento de entradas visuales mediante una secuencia de parches embebidos [6]. En este trabajo, el tensor tridimensional generado a partir del tráfico de red se procesa como una entrada multicanal, de modo que la estructura temporal y espacial de la sesión pueda ser representada mediante tokens de parches. Esta decisión es coherente con trabajos recientes que emplean representaciones visuales de flujos de red para tareas de detección de intrusiones con modelos basados en visión [9].

El proceso comienza con la partición del tensor de entrada en parches uniformes y no superpuestos. Cada parche se reorganiza y se proyecta mediante una capa lineal hacia un espacio latente de dimensión fija, precedida y seguida por normalización de capa. A la secuencia resultante se le antepone un token de clasificación aprendible, denotado como *CLS*, y se añade una codificación posicional paramétrica para conservar información relativa a la ubicación de cada parche dentro de la representación. En la implementación utilizada, este token *CLS* actúa como la representación global que será empleada tanto por el cabezal de clasificación como por las etapas posteriores de análisis latente.

La secuencia completa se procesa mediante bloques Transformer compuestos por normalización de capa, autoatención multicabezal, conexiones residuales y una red feed-forward interna con activación GELU. El mecanismo de atención permite que cada token incorpore información de otros tokens de la secuencia, sin restringirse únicamente a vecindarios locales. De forma general, la atención escalada por producto punto puede expresarse como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (5)$$

donde Q , K y V representan las matrices de consultas, claves y valores, respectivamente, y d_k corresponde a la dimensión utilizada para escalar el producto punto.

Finalmente, la salida correspondiente al token *CLS* del último bloque Transformer se introduce en un cabezal compuesto por normalización de capa y una proyección lineal hacia las clases conocidas. Esta proyección produce logits

$z_i(x)$, no probabilidades normalizadas de manera explícita dentro del método `forward`. Si se requiere interpretar los logits como una distribución cerrada sobre las K clases conocidas, puede aplicarse la función Softmax:

$$P(y_i | x) = \frac{e^{z_i(x)}}{\sum_{j=1}^K e^{z_j(x)}}. \quad (6)$$

Sin embargo, en la metodología propuesta, estos *logits* no constituyen por sí solos el criterio final de decisión para el escenario de conjunto abierto durante la fase de inferencia. Para preparar el espacio latente hacia este objetivo, durante la fase de entrenamiento las predicciones del modelo se optimizan mediante una función objetivo compuesta. En primer lugar, para abordar el desbalance de clases del dominio conocido y evitar que las mayoritarias dominen el gradiente, los *logits* alimentan una pérdida focal ponderada. Sea p_t la probabilidad estimada de la clase verdadera y α_t el peso inverso de la frecuencia de dicha clase, la pérdida se define con un factor de enfoque $\gamma = 2,0$:

$$\mathcal{L}_{\text{focal}} = -\frac{1}{N} \sum_{i=1}^N \alpha_t^{(i)} (1 - p_t^{(i)})^\gamma \log(p_t^{(i)}) \quad (7)$$

Simultáneamente, la representación latente extraída del token CLS se somete a una regularización de Fisher diseñada para compactar las características intra-clase y maximizar la separación inter-clase, facilitando la posterior detección OOD. Para garantizar la estabilidad geométrica, esta pérdida se calcula *exclusivamente* sobre las muestras del minibatch que han sido correctamente clasificadas por el modelo en ese paso.

Sea $\mathcal{X}_k$ el subconjunto de características latentes del minibatch pertenecientes a la clase k que fueron predichas correctamente. El centroide local del minibatch se define como $\mu_k^{(B)} = \frac{1}{|\mathcal{X}_k|} \sum_{x \in \mathcal{X}_k} x$. Para mantener un perfil geométrico suavizado entre iteraciones, los centroides globales μ_k se actualizan mediante una media móvil exponencial (EMA) con un factor de retención (momentum) $m = 0,5$:

$$\mu_k \leftarrow m\mu_k + (1 - m)\mu_k^{(B)} \quad (8)$$

A partir de estos centroides actualizados, se calcula la varianza intra-clase (S_W) y la varianza inter-clase (S_B). Siendo μ_G el centroide global de todas las muestras válidas del minibatch, la regularización de Fisher se formula como:

$$\mathcal{L}_{\text{Fisher}} = \frac{S_W}{S_B + \epsilon} = \frac{\frac{1}{\sum_k |\mathcal{X}_k|} \sum_k \sum_{x \in \mathcal{X}_k} \|x - \mu_k\|^2}{\sum_k \frac{|\mathcal{X}_k|}{\sum_j |\mathcal{X}_j|} \|\mu_k^{(B)} - \mu_G\|^2 + \epsilon} \quad (9)$$

donde $\epsilon = 10^{-6}$ asegura la estabilidad numérica cuando las clases están perfectamente separadas. Finalmente, la función objetivo total $\mathcal{L}_{\text{total}}$ combina ambos términos mediante un factor de decaimiento exponencial $\lambda(p)$. En lugar de un peso constante o creciente, se adoptó esta estrategia de reducción para imponer una fuerte regularización geométrica en las etapas iniciales del entrenamiento. Esto fuerza a la red a compactar el espacio latente antes de que los pesos se ajusten excesivamente a la tarea discriminativa de la pérdida focal. Conforme avanza el entrenamiento, la restricción de Fisher se relaja progresivamente, permitiendo que la pérdida principal refine las fronteras de decisión sin comprometer la estabilidad de los centroides previamente formados:

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{focal}} + \lambda(p)\mathcal{L}_{\text{Fisher}} \quad (10)$$

donde el factor dinámico se define como $\lambda(p) = 0,05 \exp(-5p)$, siendo $p \in [0, 1]$ la proporción del progreso actual respecto al número total de épocas. Esta función decrece desde 0,05 en la primera época hasta un valor residual cercano a 0,0003 al finalizar el entrenamiento.

3.5. Reconocimiento activo de conjuntos abiertos (OSR) y rechazo de distancia latente

La etapa final de la arquitectura transforma la salida del clasificador ViT en un procedimiento de reconocimiento de conjunto abierto. Este parte del embedding del token CLS producido por el ViT para cada tensor de entrada. A diferencia de una clasificación cerrada directa, estos embeddings se

someten a una cadena de transformación latente. En primer lugar, PCA se ajusta exclusivamente con los embeddings del subconjunto de entrenamiento de clases conocidas, conservando la varianza objetivo definida en la configuración experimental.

Posteriormente, las proyecciones resultantes se emplean para calibrar una transformación de cuantiles a una distribución gaussiana, la cual normaliza las representaciones latentes antes de delimitar los perfiles geométricos. Sobre este espacio transformado se calculan, para cada clase conocida k , un centroide μ_k y una matriz de covarianza Σ_k . Dado que la alta retención de varianza exigida en la proyección PCA incrementa el riesgo de colinealidad, el modelo es susceptible a inestabilidad numérica durante la inversión matricial requerida por la distancia de Mahalanobis. Para mitigar este efecto y asegurar el correcto condicionamiento, se aplica una regularización de *ridge* (Tikhonov) sobre la diagonal principal. La matriz de covarianza regularizada se define como $\Sigma_k^* = \Sigma_k + \epsilon I$, partiendo de un parámetro de estabilización inicial $\epsilon = 10^{-6}$. Si al verificar la condición numérica de la matriz resultante se detectan singularidades, el valor de ϵ se incrementa iterativamente en órdenes de magnitud hasta garantizar una inversión finita y estable.

Para una muestra de entrada x , sea $f(x)$ su representación latente obtenida tras la secuencia de análisis de componentes principales (PCA) y gaussianización por cuantiles. La distancia de Mahalanobis cuadrática hacia la clase conocida k se define como:

$$d_k^2(x) = (f(x) - \mu_k)^T \Sigma_k^{-1} (f(x) - \mu_k), \quad (11)$$

donde μ_k es el centroide de la clase k y Σ_k^{-1} representa la matriz de covarianza inversa regularizada correspondiente. La clase geométrica candidata se obtiene seleccionando la menor distancia entre todas las clases conocidas:

$$k^* = \arg \min_{k \in \{1, \dots, K\}} d_k^2(x). \quad (12)$$

La decisión abierta no se toma únicamente a partir de k^* . Para cada clase conocida se calibra un umbral τ_k usando exclusivamente las distancias de las muestras del subconjunto de validación de clases conocidas pertenecientes a la clase




Fig. 1. Flujo metodológico compacto de OSR-ViT, desde la preparación de datos y la generación RGB-E hasta el entrenamiento supervisado y la evaluación de conjunto abierto.

real k hacia su propio perfil de Mahalanobis. Con el objetivo de reducir la sensibilidad a valores extremos, el umbral se calcula mediante la mediana y la desviación absoluta de la mediana:

$$\tau_k = \text{median}(D_k) + \lambda_{\text{MAD}} \text{MAD}(D_k), \quad (13)$$

donde D_k es el conjunto de distancias de validación de la clase k , y λ_{MAD} es el factor de sensibilidad del rechazo, evaluado mediante una rejilla de valores candidatos durante el análisis de sensibilidad. En inferencia, el sistema calcula una puntuación normalizada:

$$s(x) = \frac{d_{k^*}^2(x)}{\tau_{k^*}}. \quad (14)$$

La muestra se acepta como perteneciente a la clase conocida k^* si $s(x) < 1$. En caso contrario, se rechaza como instancia OOD:

$$g(x) = \begin{cases} k^*, & \text{si } s(x) < 1, \\ \text{OOD}, & \text{si } s(x) \geq 1. \end{cases} \quad (15)$$

De este modo, la función de decisión $g(x)$ concluye el flujo metodológico del enfoque propuesto, estableciendo un límite geométrico explícito en el espacio latente para la mitigación activa de amenazas no observadas.

4. Configuración experimental y estrategia de evaluación

4.1. Conjunto de datos y aislamiento determinista de día cero

Para validar la arquitectura propuesta, el experimento utiliza el conjunto de datos CSE-CIC-IDS2018 bajo un esquema estructurado en cuatro particiones conceptuales. Este diseño establece una frontera estricta entre el dominio supervisado y las amenazas fuera de distribución, garantizando que el modelo sea evaluado frente a muestras no observadas durante su ajuste [16, 20, 14]. La Tabla 1 presenta las jornadas del conjunto de datos descargadas y empleadas en el experimento, junto con las principales familias de ataque registradas en cada una de ellas.

Tabla 1. Jornadas del conjunto CSE-CIC-IDS2018 empleadas en el experimento.

Fecha	Día	Actividad principal
16/02/2018	Viernes	DoS
21/02/2018	Miércoles	DDoS
22/02/2018	Jueves	Web_Attack
02/03/2018	Viernes	Botnet

El dominio de clases conocidas se conformó con tráfico benigno y con las familias DoS, incluyendo variantes como *SlowHTTPTest* y

Hulk, y DDoS, representada por ataques LOIC y HOIC. Las muestras pertenecientes a este dominio se distribuyeron mediante una partición basada en hash en proporciones del 80 % para entrenamiento, 10 % para validación y 10 % para prueba. La asignación se calculó aplicando la función hash SHA-256 sobre una clave de agrupación compuesta por el día de la captura y la tupla bidireccional canónica de la sesión (IP origen, IP destino, puertos y protocolo). Esta estrategia garantiza que todas las comunicaciones iterativas entre un mismo par de hosts bajo el mismo servicio durante una jornada se agrupen estrictamente en la misma partición, evitando que sesiones temporalmente relacionadas de una misma campaña crucen entre el conjunto de entrenamiento y los conjuntos de evaluación. Para controlar el volumen de procesamiento sin requerir generación sintética, se aplicaron tasas de retención deterministas. Esta estrategia de submuestreo busca mitigar el desbalance extremo del tráfico original y evitar que la clase mayoritaria (*Benign*) sature el espacio latente y el cálculo del gradiente. El subconjunto de entrenamiento retuvo el 1.5% de las muestras *Benign* y el 9% de las clases DoS y DDoS, mientras que los subconjuntos de validación y prueba de clases conocidas mantuvieron una tasa uniforme del 5%. Aunque esta decisión altera la prevalencia natural de las clases en la red, asegura un volumen absoluto estadísticamente significativo para validar las fronteras geométricas del modelo.

Por otro lado, el aislamiento de amenazas de día cero se definió a nivel de familia de ataque, designando a *Botnet* y *Web_Attack*—esta última agrupando los subtipos *Brute Force-Web*, *Brute Force-XSS* y *SQL Injection*—estrictamente como clases OOD. Para asegurar la integridad de la evaluación abierta, estas familias se excluyeron por completo de las fases de entrenamiento, normalización global y calibración de umbrales, siendo enrutadas con un 100% de retención exclusivamente hacia el subconjunto independiente de prueba OOD.

4.2. Configuración de la Ventana Temporal de Entrada

El diseño de la ventana temporal de entrada requiere equilibrar la cantidad de paquetes conservados por sesión y el costo computacional asociado al procesamiento del tensor. En modelos IDS basados en representaciones visuales, el número de paquetes observados define la capacidad del clasificador para preservar patrones tempranos de cabeceras, tiempos relativos y carga útil. En lugar de procesar flujos de longitud arbitraria, la arquitectura propuesta ingiere tensores con una dimensión espacial fija de $[N_{\min}, 144, 3]$. El parámetro $N_{\min}$ unifica la semántica de la ventana de observación: establece el número mínimo de paquetes requeridos para que una sesión sea admitida en el corpus y, simultáneamente, define el límite máximo de paquetes retenidos mediante truncamiento. Esta doble restricción garantiza una entrada consistente, compatible con el mecanismo de partición en parches del ViT, y elimina por completo la necesidad de rellenar conexiones cortas.

En los experimentos se adoptó un tamaño de ventana de $N_{\min} = 7$ paquetes aplicado de manera uniforme en todas las fases del protocolo experimental. Esta elección se basa en la evidencia de que las representaciones secuenciales de paquetes permiten identificar actividad maliciosa en etapas tempranas de la comunicación, sin esperar la finalización completa del flujo. En particular, Ghadermazi et al. [7] muestran que el desempeño de un NIDS basado en imágenes de paquetes secuenciales mejora conforme aumenta el número de paquetes iniciales observados y alcanza su mejor comportamiento alrededor de nueve paquetes. En este trabajo se adoptó una ventana ligeramente menor, $N_{\min} = 7$, para preservar una mayor cantidad de sesiones válidas bajo el filtro estricto de longitud mínima, manteniendo al mismo tiempo una representación temprana de la comunicación. Bajo esta configuración temporal, el sistema evalúa el rendimiento de clasificación de conjunto cerrado sobre clases conocidas y el comportamiento del rechazo de conjunto abierto frente a amenazas inéditas. Las métricas de evaluación específicas derivadas de la matriz de confusión y del análisis de umbrales

—tales como el Coeficiente de Correlación de Matthews (MCC) y AUROC OOD— se formulan y justifican en detalle en la Sección 4.5.

4.3. Configuración del análisis de sensibilidad del módulo OSR

Para la caracterización del espacio latente, los hiperparámetros del módulo de reconocimiento abierto se resumen en la Tabla 2. La configuración del PCA no se orientó hacia una compresión agresiva de la dimensionalidad, sino a operar como un filtro de colinealidad. Por ello, se retuvo la máxima expresividad del *embedding* original del ViT, eliminando únicamente las dependencias lineales perfectas que imposibilitarían el cálculo posterior de las matrices de covarianza.

Posteriormente, la proyección resultante se sometió a una transformación por cuantiles. Este paso es un requisito para mitigar el sesgo de las colas pesadas típicas del tráfico de red y satisfacer el supuesto subyacente de normalidad multivariada que exige la distancia de Mahalanobis. Los parámetros de resolución y submuestreo de este algoritmo se establecieron para equilibrar la precisión de la transformación con el costo de memoria.

Tabla 2. Configuración de hiperparámetros del módulo de Reconocimiento de Conjunto Abierto.

Componente / Parámetro	Valor
PCA	0,999999
Máximo de cuantiles	10,000
Submuestra de calibración	100,000

La sensibilidad del mecanismo de rechazo se evaluó mediante la rejilla:

$$\lambda_{\text{MAD}} \in \{1,00, 1,25, 1,50, 1,75, 2,00, 3,00, 4,50, 7,00\}.$$

La calibración del parámetro λ_{MAD} se realizó de manera estricta sobre la partición de validación de clases conocidas. A diferencia de una selección orientada únicamente a maximizar la sensibilidad frente a muestras fuera de distribución, el punto operativo del escudo OSR se definió considerando la viabilidad práctica del IDS y el falso rechazo inducido sobre el tráfico conocido. Esta decisión sigue el criterio de que un IDS debe operar en

una región de baja tasa de falsos positivos o falsos desconocidos, ya que tasas elevadas de rechazo erróneo pueden generar sobrecarga operativa y fatiga de alertas [16, 15]. Asimismo, la literatura sobre calibración de umbrales en IDS muestra que la elección del punto operativo debe responder a un compromiso entre detección de tráfico anómalo y preservación de la precisión del sistema, en función de los requisitos reales del entorno de despliegue [19].

Por ello, se adoptó un criterio de control explícito del falso rechazo en validación. En particular, se seleccionó el menor valor de la rejilla que mantuviera la tasa de falso rechazo de clases conocidas por debajo o igual al 20 %, límite utilizado en la literatura para caracterizar una región realista de despliegue en evaluación OOD de IDS [16]. Formalmente, este criterio se define como:

$$\lambda_{\text{MAD}}^* = \min \{ \lambda \in \Lambda : \text{FRR}_{\text{val}}(\lambda) \leq 0,20 \}. \quad (16)$$

Siguiendo esta regla, el hiperparámetro se fijó en $\lambda_{\text{MAD}}^* = 2,00$, al ser el primer valor de la rejilla que cumple la restricción operativa, con $\text{FRR}_{\text{val}} = 0,1929$. Este valor se congeló para la fase de evaluación final, garantizando que las métricas de prueba se emplearan exclusivamente para evaluar el punto de operación elegido, sin influir en su ajuste.

4.4. Protocolo de evaluación de reconocimiento de conjunto abierto

Para estructurar la evaluación de conjunto abierto, el entorno de evaluación combinó el subconjunto de prueba de clases conocidas y el subconjunto de prueba de conjunto abierto. Apoyándose en el aislamiento estricto definido en la Sección 4.1, esta organización permite analizar el comportamiento del escudo OSR tanto en una tarea de clasificación binaria (discriminación entre clases conocidas y tráfico OOD) como mediante un desglose específico por familia y subtipo de amenaza no observada.

La decisión abierta se obtiene normalizando la distancia mínima de Mahalanobis por el umbral MAD de la clase geométrica ganadora. Si el valor de decisión normalizado supera el punto

de rechazo, la muestra se marca como OOD; de lo contrario, se acepta como perteneciente a la clase conocida más cercana. Los umbrales se calibran con el subconjunto de validación de clases conocidas mediante mediana y desviación absoluta de la mediana, mientras que λ_{MAD} controla la sensibilidad del rechazo y se analiza mediante una rejilla de valores candidatos. Para la evaluación final, el punto operativo del escudo OSR se fija a partir del análisis de sensibilidad realizado sobre la configuración experimental definida.

La evaluación multi-escenario se diseña para analizar tanto la separación de clases conocidas vs. OOD como el efecto del escudo sobre las clases conocidas; las métricas empleadas para cuantificar estos efectos se describen en la Sección 4.5.

4.5. Criterios y métricas de evaluación

La estrategia de evaluación se organiza en dos niveles complementarios: una evaluación de dominio cerrado sobre clases conocidas y una evaluación de conjunto abierto orientada a distinguir muestras conocidas de tráfico OOD. La primera permite medir el desempeño del clasificador ViT dentro del dominio supervisado, mientras que la segunda evalúa el efecto del escudo OSR sobre el rechazo de amenazas no observadas durante el entrenamiento. Esta separación evita mezclar la capacidad de clasificación entre clases conocidas con la capacidad de detección de muestras fuera de distribución, que responde a un criterio de decisión distinto [15].

En la evaluación de conjunto cerrado, el modelo se aplica sobre el subconjunto de prueba de clases conocidas y se construye una matriz de confusión multicategoría. A partir de esta matriz se calculan Accuracy, Macro Precision, Macro Recall, Macro F1, Weighted F1, MCC y métricas por clase, incluyendo Precision, Recall, FNR, F1 y soporte. Para cada clase k , el Recall y la FNR se definen como:

$$\text{Recall}_k = \frac{TP_k}{TP_k + FN_k}, \quad (17)$$

$$\text{FNR}_k = \frac{FN_k}{TP_k + FN_k} = 1 - \text{Recall}_k. \quad (18)$$

Debido al desbalance característico del tráfico de red, el Coeficiente de Correlación de Matthews (MCC) se utiliza como métrica global relevante, ya que considera simultáneamente aciertos, errores y distribución de clases [5]. En el caso multicategoría empleado por la implementación, el MCC se calcula como:

$$\text{MCC} = \frac{cs - \sum_k p_k t_k}{\sqrt{(s^2 - \sum_k p_k^2)(s^2 - \sum_k t_k^2)}}, \quad (19)$$

donde c es el número total de predicciones correctas, s es el número total de muestras, p_k es el total de predicciones asignadas a la clase k , y t_k es el soporte real de la clase k .

En la evaluación *open-set*, el sistema combina el subconjunto de prueba de clases conocidas con el subconjunto de prueba OOD. La decisión binaria se formula como una tarea de clases conocidas vs. OOD, donde las muestras conocidas deberían ser aceptadas por el escudo y las muestras OOD deberían ser rechazadas. Para ello, se emplea el score continuo normalizado del módulo OSR, definido como la distancia cuadrática mínima de Mahalanobis dividida por el umbral MAD de la clase geométrica ganadora. Sobre este score se calculan AUROC OOD y AUPR OOD, con el fin de estimar la capacidad de separación entre muestras conocidas y fuera de distribución sin depender únicamente de un único punto de corte.

Además de AUROC y AUPR, la evaluación de conjunto abierto reporta MCC binario Known/OOD, OOD Recall, OOD FNR, Precision OOD, F1 OOD y Balanced Accuracy y tasa de falso rechazo de muestras conocidas. Para la clase positiva OOD, la tasa de falsos negativos se define como:

$$\text{OOD FNR} = \frac{FN_{\text{OOD}}}{FN_{\text{OOD}} + TP_{\text{OOD}}}, \quad (20)$$

mientras que la tasa de falso rechazo de conocidos mide la proporción de muestras conocidas clasificadas erróneamente como OOD:

$$\text{Known FRR} = \frac{FP_{\text{OOD}}}{FP_{\text{OOD}} + TN_{\text{OOD}}}. \quad (21)$$

Finalmente, se cuantifica la degradación inducida por el escudo OSR sobre el dominio conocido mediante el MCC antes y después del rechazo, y el número de muestras conocidas rechazadas.

En conjunto, estas métricas permiten analizar el compromiso entre sensibilidad frente a amenazas OOD y preservación del rendimiento sobre tráfico conocido.

5. Resultados y Discusión

5.1. Distribución de datos experimentales

La distribución experimental para el punto operativo $N_{\min} = 7$ se detalla en la Tabla 3. Tras aplicar las tasas de retención definidas experimentalmente, el corpus de evaluación consta de un total de 570,791 muestras.

Tabla 3. Distribución final de muestras por partición para $N_{\min} = 7$.

Clase	Train	Val	Test-K	Test-OOD	Total
Benign	130,369	54,476	54,482	0	239,327
DoS	130,294	9,922	8,207	0	148,423
DDoS	76,912	4,864	5,179	0	86,955
Botnet	0	0	0	95,893	95,893
Web_Attack	0	0	0	193	193
Total	337,575	69,262	67,868	96,086	570,791

En las particiones de clases conocidas se observa un desbalance moderado entre Benign, DoS y DDoS. El entrenamiento concentra principalmente muestras Benign y DoS, mientras que DDoS presenta un volumen menor. En contraste, la partición OOD presenta un predominio marcado de la familia *Botnet* (95,893 muestras) frente a *Web_Attack*. Esta última incluye una representación reducida pero específica de 135 muestras de *Brute Force-Web*, 42 de *Brute Force-XSS* y 16 de *SQL Injection*. La reducida volumetría de *Web_Attack* a pesar de su política de retención del 100%, responde a la naturaleza del tráfico crudo y al filtro estructural impuesto por la ventana de observación. Gran parte de los vectores de ataque web en el conjunto de datos original consisten en conexiones efímeras, escaneos abortados o peticiones HTTP simples que no alcanzan el umbral estricto de $N_{\min} = 7$ paquetes, siendo descartados sistemáticamente para garantizar la integridad temporal de los tensores. Esta diferencia de volumetría debe considerarse métricamente al interpretar los resultados agregados del rechazo OOD reportados en los escenarios posteriores.

La siguiente subsección presenta los resultados obtenidos sobre las clases conocidas antes de analizar el comportamiento abierto frente a Botnet y *Web_Attack*.

5.2. Rendimiento de clasificación de conjuntos cerrados

El desempeño de conjunto cerrado del clasificador ViT se evaluó sobre el subconjunto de prueba de clases conocidas para $N_{\min} = 7$. La Tabla 4 resume las métricas globales obtenidas.

Tabla 4. Métricas globales de clasificación *closed-set* para $N_{\min} = 7$.

Métrica	Valor
Accuracy	0.9995
MCC	0.9986
Macro Precision	0.9979
Macro Recall	0.9998
Macro F1	0.9989
Weighted F1	0.9995

Los resultados muestran un alto desempeño de clasificación multiclase, alcanzando una Accuracy de 0.9995 y un MCC de 0.9986. Las métricas macro, cercanas a 1.0000, evidencian un comportamiento estable entre las distintas clases.

La matriz de confusión se presenta en la Tabla 5. Los errores se concentran únicamente en muestras benignas asignadas a clases de ataque, principalmente como DDoS. En contraste, las clases DoS y DDoS no registran falsos negativos en esta evaluación, lo que indica que los ataques conocidos del subconjunto de prueba no fueron confundidos con tráfico benigno.

El análisis por clase, mostrado en la Tabla 6, confirma un comportamiento estable entre las clases conocidas. La ligera reducción de Precision en DDoS se explica por las muestras benignas clasificadas como DDoS, mientras que Benign mantiene Precision perfecta porque ninguna muestra DoS o DDoS fue clasificada como tráfico benigno. Este patrón es relevante desde la perspectiva IDS, ya que los errores observados no corresponden a ataques conocidos aceptados como benignos.

Tabla 5. Matriz de confusión de la evaluación *closed-set* para $N_{\min} = 7$.

Clase verdadera	Predicción			
	Benign	DoS	DDoS	Soporte
Benign	54,449	1	32	54,482
DoS	0	8,207	0	8,207
DDoS	0	0	5,179	5,179

Tabla 6. Métricas por clase en la evaluación *closed-set* para $N_{\min} = 7$.

Clase	Precision	Recall	F1	FNR	Soporte
Benign	1.0000	0.9994	0.9997	0.0006	54,482
DoS	0.9999	1.0000	0.9999	0.0000	8,207
DDoS	0.9939	1.0000	0.9969	0.0000	5,179

5.3. Análisis de sensibilidad de OSR con λ_{MAD}

El parámetro λ_{MAD} controla la amplitud de las fronteras de aceptación del módulo OSR. Los valores reducidos generan umbrales más restrictivos y, por tanto, una mayor proporción de muestras conocidas rechazadas como OOD. Por el contrario, el incremento de λ_{MAD} amplía los umbrales por clase y reduce el falso rechazo. La Tabla 7 presenta este comportamiento para los valores evaluados en la rejilla de sensibilidad.

Tabla 7. Calibración del punto operativo mediante FRR y umbrales por clase según λ_{MAD} para $N_{\min} = 7$.

λ_{MAD}	FRR _{val}	τ_{Benign}	τ_{DoS}	τ_{DDoS}
1.00	0.2935	248.15	251.10	255.96
1.25	0.2611	261.50	262.55	264.64
1.50	0.2344	274.86	274.00	273.33
1.75	0.2113	288.22	285.44	282.01
2.00	0.1929	301.58	296.89	290.69
3.00	0.1396	355.01	342.68	325.42
4.50	0.0932	435.15	411.36	377.52
7.00	0.0546	568.73	525.83	464.35

Los resultados muestran una reducción monótonica del FRR global conforme aumenta λ_{MAD} . El falso rechazo disminuye de 0,2935 para $\lambda_{MAD} = 1,00$ a 0,0546 para $\lambda_{MAD} = 7,00$. Esta variación es consistente con el incremento de los umbrales τ_k , dado que una frontera más amplia permite aceptar una mayor proporción de muestras conocidas.

Los umbrales no evolucionan de manera idéntica entre clases. Para valores reducidos de λ_{MAD} , las diferencias entre τ_{Benign} , τ_{DoS} y τ_{DDoS} son moderadas. Sin embargo, estas diferencias aumentan progresivamente durante el barrido. Con $\lambda_{MAD} = 7,00$, los umbrales alcanzan 568,73, 525,83 y 464,35, respectivamente. Este comportamiento refleja las diferencias en la mediana y en la dispersión MAD de las distancias de validación de cada clase, por lo que la calibración mantiene fronteras específicas en lugar de aplicar un umbral global común.

La disminución del FRR no se utilizó como un objetivo de minimización aislado, ya que el incremento de λ_{MAD} amplía simultáneamente las regiones de aceptación de las clases conocidas y puede reducir la sensibilidad frente a muestras OOD. Por ello, la calibración se formuló como un compromiso operativo entre preservación del tráfico conocido y detección de amenazas fuera de distribución. Este enfoque es consistente con la literatura sobre IDS/OOD, donde se recomienda seleccionar umbrales dentro de regiones de baja tasa de falsos positivos o falsos desconocidos y ajustar el rechazo según los requisitos reales del sistema [16, 15, 19].

De acuerdo con el criterio definido en la Sección 4.3, se seleccionó el menor valor de la rejilla que cumple $FRR_{val}(\lambda) \leq 0,20$. Los valores $\lambda_{MAD} = 1,50$ y $\lambda_{MAD} = 1,75$ reducen el falso rechazo respecto a configuraciones más estrictas, pero mantienen $FRR_{val} = 0,2344$ y $FRR_{val} = 0,2113$, respectivamente. En cambio, $\lambda_{MAD} = 2,00$ alcanza $FRR_{val} = 0,1929$, siendo el primer punto que satisface la restricción operativa establecida.

Para complementar la selección del punto operativo, se realizó un análisis post-hoc de sensibilidad del umbral manteniendo fijo el modelo entrenado, los *embeddings* latentes, la proyección PCA, la transformación por cuantiles y los perfiles de Mahalanobis por clase. En consecuencia, este análisis no modifica la arquitectura ni el entrenamiento del modelo, sino únicamente el valor de λ_{MAD} utilizado por el escudo OSR para evaluar el compromiso entre rechazo de tráfico conocido y detección de muestras OOD.

La Figura 2 resume la variación de $Recall_{OOD}$, $F1_{OOD}$ y FRR_{Known} frente a los valores eva-

luados de λ_{MAD} . Se observa que los valores más restrictivos de λ_{MAD} preservan una mayor sensibilidad OOD, pero inducen un mayor rechazo de muestras conocidas. Por el contrario, al incrementar λ_{MAD} , el falso rechazo conocido disminuye de manera progresiva, mientras que las métricas de detección OOD se reducen. Este comportamiento complementa la lectura de la Tabla 7, al mostrar el efecto del umbral no solo sobre el falso rechazo conocido, sino también sobre las métricas OOD.




Fig. 2. Análisis post-hoc de sensibilidad del punto operativo OSR según λ_{MAD} . El modelo entrenado y las transformaciones latentes permanecen fijos; únicamente se modifica el umbral de rechazo.

La Figura 3 representa el compromiso directo entre FRR_{Known} y $Recall_{OOD}$. La línea vertical indica el límite operativo de falso rechazo conocido, mientras que los puntos de la curva muestran cómo el aumento de λ_{MAD} desplaza el sistema hacia menores tasas de rechazo conocido y menor recuperación OOD. Esta visualización permite observar la posición relativa del punto operativo seleccionado dentro del barrido evaluado.

Una vez fijado $\lambda_{MAD} = 2,00$ a partir del criterio de validación reportado en la Tabla 7, se procedió a la evaluación final sobre los subconjuntos independientes de prueba. Las métricas OOD obtenidas en prueba se presentan en la Sección 5.4. Asimismo, las curvas post-hoc incluidas en esta sección se emplean únicamente como análisis descriptivo del compromiso entre FRR_{Known} y desempeño OOD, y no formaron parte del criterio de calibración.




Fig. 3. Compromiso post-hoc entre falso rechazo conocido y recuperación OOD para los valores evaluados de λ_{MAD} .

Cabe señalar que $\lambda_{MAD} = 1,50$ representa una configuración alternativa orientada a mayor sensibilidad OOD. En validación, este punto mantiene $FRR_{val} = 0,2344$, por encima del límite operativo adoptado; mientras que, en prueba, conserva un $Recall_{OOD} = 0,9006$ con $FRR_{Known} = 0,2347$. Por esta razón, se interpreta como una opción de alta sensibilidad, pero no como el punto operativo principal bajo el criterio de $FRR_{val} \leq 0,20$.

5.4. Resultados de detección de día cero en conjunto abierto

La evaluación *open-set* se realizó con el punto operativo seleccionado en el análisis de sensibilidad, correspondiente a $N_{mín} = 7$ y $\lambda_{MAD} = 2,00$. La Tabla 8 resume las métricas obtenidas bajo esta configuración final.

El valor de $AUROC_{OOD} = 0,8280$ indica que el *score* continuo del escudo OSR conserva una separación apreciable entre las muestras conocidas y las muestras OOD. Por su parte, la métrica $AUPR_{OOD} = 0,7474$ debe interpretarse considerando su prevalencia base. En el subconjunto binario combinado, la clase positiva OOD representa aproximadamente el 58,6% del total. Dado que el rendimiento de un clasificador aleatorio en una curva Precision-Recall equivale

Tabla 8. Resultados finales de detección *open-set* para $N_{\min} = 7$ y $\lambda_{\text{MAD}} = 2,00$.

Métrica	Valor
AUROC _{OOD}	0.8280
AUPR _{OOD}	0.7474
MCC _{binario}	0.4833
Recall _{OOD}	0.6836
Precision _{OOD}	0.8335
F1 _{OOD}	0.7511
Balanced Accuracy	0.7451
FNR _{OOD}	0.3164
FRR _{Known}	0.1933

Tabla 9. Matriz de confusión de la evaluación *open-set* para $N_{\min} = 7$ y $\lambda_{\text{MAD}} = 2,00$.

Clase verdadera	Predicción		
	Known	OOD	Soporte
Known	54,750	13,118	67,868
OOD	30,406	65,680	96,086

a esta proporción base (0,586), el valor obtenido demuestra una ganancia predictiva empírica por encima del azar, caracterizando de forma transparente el rendimiento del modelo en este escenario de desbalance.

En el punto operativo seleccionado, el sistema obtuvo Recall_{OOD} = 0,6836, lo que corresponde a una detección de 65,680 muestras OOD sobre un total de 96,086. La tasa complementaria FNR_{OOD} = 0,3164 indica que 30,406 muestras OOD fueron aceptadas erróneamente como conocidas. Asimismo, el sistema alcanzó una Precision_{OOD} = 0,8335, un F1_{OOD} = 0,7511 y una Balanced Accuracy de 0,7451, lo que permite evaluar el punto operativo considerando tanto la detección de amenazas fuera de distribución como la preservación de las clases conocidas.

La matriz de confusión binaria se muestra en la Tabla 9. De las 67,868 muestras conocidas, 54,750 fueron aceptadas correctamente como conocidas y 13,118 fueron rechazadas como OOD. Este último valor explica la FRR_{Known} = 0,1933.

La Figura 4 muestra la curva ROC asociada al score continuo del escudo OSR para la tarea binaria.

Estos hallazgos muestran que el punto operativo elegido reduce el falso rechazo sobre




Fig. 4. Curva ROC de la tarea Known/OOD en la evaluación *open-set* para $N_{\min} = 7$.

el dominio conocido hasta FRR_{Known} = 0,1933, manteniéndolo dentro de la restricción operativa definida en validación. Este ajuste implica un compromiso esperado: al ampliar las fronteras de aceptación para preservar más tráfico conocido, la recuperación de amenazas OOD disminuye a Recall_{OOD} = 0,6836. Por tanto, la configuración final prioriza una operación más viable del escudo OSR frente al falso rechazo conocido, sin eliminar por completo su capacidad de detección de amenazas fuera de distribución.

5.5. Análisis OOD por clase y por subtipo

Dado el pronunciado desbalance volumétrico dentro de la partición fuera de distribución, donde la familia Botnet representa aproximadamente el 99,8% del soporte evaluado, las métricas agregadas globales caracterizan principalmente el rendimiento del modelo frente a esta amenaza dominante. Para complementar esta lectura, el análisis se desagrega a nivel de familia y subtipo OOD. La Tabla 10 reporta el número de muestras detectadas, el Recall_{OOD} y la mediana del score

normalizado de rechazo.

Tabla 10. Desglose de resultados OOD por familia y subtipo para $N_{\min} = 7$ y $\lambda_{\text{MAD}} = 2,00$.

Familia / Subtipo	Detectadas	Rec _{OOD}	Mediana $s(x)$
Botnet	65,487	0.6829	1.0641
Web Attack (Total)	193	1.0000	10.8033
– Brute Force-Web	135	1.0000	9.9698
– Brute Force-XSS	42	1.0000	18.2201
– SQL Injection	16	1.0000	15.5412

Los resultados para Botnet muestran un $\text{Recall}_{\text{OOD}} = 0,6829$, con una mediana del *score* normalizado igual a 1.0641. Dado que el umbral de rechazo corresponde a $s(x) = 1$, este valor sugiere que una proporción relevante de sus muestras se ubica cerca de la frontera de aceptación y rechazo. Esta proximidad al umbral es consistente con los falsos negativos OOD observados en la evaluación binaria global.

En contraste, la categoría agregada Web_Attack presentó un soporte considerablemente menor, pero todas sus muestras fueron rechazadas como OOD bajo el punto operativo seleccionado. La mediana del *score* normalizado fue de 10,8033, lo que indica una separación más amplia respecto de la frontera de rechazo en comparación con Botnet. Sin embargo, esta lectura debe interpretarse considerando el bajo número de muestras disponibles para esta familia.

El desglose por subtipo mantiene el mismo patrón para los ataques web evaluados. Brute Force-Web, Brute Force-XSS y SQL Injection alcanzaron un $\text{Recall}_{\text{OOD}} = 1,0000$, con medianas del *score* normalizado de 9,9698, 18,2201 y 15,5412, respectivamente. Estos resultados sugieren que, dentro del subconjunto analizado, los ataques web se ubican más alejados de las regiones de aceptación de las clases conocidas. No obstante, debido al soporte reducido de estos subtipos, especialmente en SQL Injection, estos resultados deben considerarse como evidencia descriptiva del conjunto evaluado y no como una generalización definitiva para todos los ataques de capa de aplicación.

5.6. Discusión

Los resultados obtenidos deben interpretarse en dos niveles complementarios. En primer lugar, el clasificador ViT conserva un desempeño elevado en el escenario de conjunto cerrado, lo que indica que la representación RGB-E y el aprendizaje supervisado permiten separar adecuadamente las clases conocidas bajo las condiciones experimentales definidas. En segundo lugar, el módulo OSR añade una regla geométrica de aceptación y rechazo basada en distancias de Mahalanobis, permitiendo que el sistema no dependa únicamente de la asignación cerrada de clases. Desde esta perspectiva, el aporte metodológico principal no reside solo en la predicción de etiquetas conocidas, sino en la incorporación de un mecanismo explícito para delimitar el dominio de conocimiento del modelo.

La selección de $\lambda_{\text{MAD}} = 2,00$ debe entenderse como una decisión de calibración operativa. El objetivo no fue maximizar de forma aislada la sensibilidad frente a tráfico OOD, sino controlar el falso rechazo de muestras conocidas bajo el criterio definido en validación. Esta elección desplaza el sistema hacia una configuración más conservadora respecto al tráfico conocido, aceptando una reducción en la recuperación OOD. En un IDS, este compromiso es relevante porque un punto operativo demasiado restrictivo puede incrementar la carga de revisión y generar rechazos frecuentes de tráfico legítimo, mientras que un umbral demasiado permisivo puede reducir la detección de amenazas fuera de distribución. Por ello, la calibración del escudo OSR debe interpretarse como una decisión dependiente de las tolerancias de seguridad y disponibilidad del entorno de despliegue [16, 15, 19].

El análisis por familia OOD sugiere que la eficacia del rechazo geométrico no es uniforme para todos los tipos de amenaza. En particular, los resultados indican que algunas familias OOD pueden ubicarse cerca de las regiones de aceptación de clases conocidas, mientras que otras presentan una separación latente más amplia. Esta diferencia es coherente con la naturaleza heterogénea del tráfico malicioso y con trabajos que señalan la dificultad de distinguir ciertos patrones Botnet cuando comparten rasgos

temporales o transaccionales con tráfico rutinario [14]. Por tanto, la evaluación agregada debe complementarse con análisis desagregados, especialmente cuando el subconjunto OOD presenta un fuerte desbalance entre familias.

El alcance de estos resultados se circunscribe al diseño experimental empleado: clases conocidas Benign, DoS y DDoS; familias OOD Botnet y Web_Attack; representación RGB-E con $N_{\min} = 7$; y calibración OSR mediante umbrales MAD sobre el espacio latente transformado. En consecuencia, los resultados permiten evaluar el comportamiento del enfoque bajo un escenario controlado de día cero, pero no deben extrapolarse directamente a todas las variantes de tráfico desconocido ni a condiciones de despliegue dinámico sin una validación adicional. Las limitaciones específicas de este alcance y sus implicancias para trabajos futuros se discuten en la sección final correspondiente.

5.7. Comparación con trabajos relacionados

Los resultados de OSR-ViT se contextualizan frente a trabajos relacionados mediante dos escenarios independientes. El primero comprende evaluaciones *closed-set* sobre CSE-CIC-IDS2018, mientras que el segundo reúne estudios que incorporan mecanismos explícitos de reconocimiento de conjunto abierto. Esta separación evita interpretar conjuntamente métricas obtenidas bajo formulaciones diferentes. Asimismo, los valores reportados se presentan como referencias dentro del protocolo experimental de cada estudio y no como una clasificación directa de rendimiento, debido a las diferencias en la unidad de análisis, la representación de entrada, el número de clases, las estrategias de partición y la definición de las muestras OOD.

La Tabla 11 presenta una contextualización de resultados de dominio cerrado reportados sobre CSE-CIC-IDS2018.

Bajo su protocolo experimental, OSR-ViT alcanzó una Accuracy de 0,9995 y un Macro F1 de 0,9989 sobre tres clases conocidas. El antecedente arquitectónico más próximo dentro de esta tabla es ViT-IDS, propuesto por Alsalamah e Ismail [1], que obtuvo una Accuracy y un F1-Score de 0,99958 sobre ocho clases. No obstante, sus

imágenes de entrada se construyen reorganizando características tabulares en matrices de 16×16 , mientras que OSR-ViT genera tensores RGB-E a partir de los primeros paquetes de cada sesión. Por tanto, ambos trabajos comparten el uso de CSE-CIC-IDS2018 y de una arquitectura ViT, pero difieren en la unidad de análisis y en el procedimiento de representación del tráfico.

Los demás estudios incluidos proporcionan referencias adicionales dentro del mismo conjunto de datos. Alzughaibi y El Khediri [2] evaluaron un MLP sobre siete categorías y 24 características seleccionadas, mientras que Mahendar y Shivakanth [12] utilizaron una CNN unidimensional sobre nueve clases y características estadísticas de flujo. Estos enfoques operan sobre entradas tabulares y no modelan directamente secuencias de paquetes. Además, los protocolos tampoco son equivalentes: OSR-ViT utiliza una partición determinista basada en hash de 80/10/10; Alsalamah e Ismail emplean una partición efectiva de 72/8/20 con submuestreo y sobremuestreo; Alzughaibi y El Khediri aplican una división 70/30 con validación cruzada de cinco pliegues; y Mahendar y Shivakanth no especifican las proporciones de partición. En consecuencia, los valores de la Tabla 11 permiten situar el rendimiento obtenido dentro de la literatura sobre CSE-CIC-IDS2018, pero no representan resultados producidos bajo condiciones experimentales homogéneas.

Por estas diferencias metodológicas, los modelos basados en secuencias de paquetes se consideran antecedentes arquitectónicos, pero no se incorporan a la comparación cuantitativa debido a su formulación binaria, al uso de conjuntos de datos distintos y a la ausencia de métricas directamente comparables.

Para el escenario *open-set*, la Tabla 12 reúne estudios que excluyen clases completas del entrenamiento y aplican un mecanismo explícito de rechazo. Las columnas resumen el conjunto de datos y la composición OOD, el procedimiento de rechazo y las métricas independientes del punto operativo disponibles. Cuando un trabajo no reporta AUROC o AUPR, se conserva como referencia metodológica y el valor se indica como no reportado.

Park y Lim [14] constituyen la referencia más

Tabla 11. Contextualización de resultados *closed-set* reportados sobre CSE-CIC-IDS2018.

Trabajo	Modelo y representación de entrada	Escenario	Accuracy	F1-Score
OSR-ViT	ViT sobre sesiones RGB-E derivadas directamente de PCAP	Multiclase (3)	0.9995	0.9989 ^a
Alsalamah e Ismail [1]	ViT-IDS sobre imágenes 16×16 derivadas de características tabulares	Multiclase (8)	0.99958	0.99958 ^b
Alzughaibi y El Khediri [2]	MLP-BP sobre 24 características tabulares seleccionadas	Multiclase (7)	0.9841	0.9920 ^b
Mahendar y Shivakanth [12]	CNN-1D sobre características tabulares estandarizadas	Multiclase (9)	0.9750	0.9570 ^b

^a Macro F1. ^b Método de agregación del F1 no especificado por los autores.

Tabla 12. Contextualización de protocolos y resultados *open-set* reportados en trabajos relacionados.

Trabajo	Dataset y escenario OOD	Mecanismo de rechazo	AUROC	AUPR
OSR-ViT	CSE-CIC-IDS2018; Botnet y Web_Attack evaluados conjuntamente	PCA, transformación cuantílica, Mahalanobis y umbrales MAD por clase	0.8280	0.7474
Zhang et al. [20]	CICIDS2017; Botnet y WebAttack evaluados individualmente	Centroide de clase más cercano y umbral basado en el percentil 99	0.9740 0.9240 ^a	0.9660 0.9260 ^{a,b}
Talpini et al. [16]	CICIDS2017; múltiples clases OOD evaluadas conjuntamente en varios escenarios	Red neuronal bayesiana, distancia de Mahalanobis y calibración sobre validación	0,7300 $\pm 0,0300$	NR

Las métricas AUROC y AUPR consideran las muestras OOD como clase positiva, salvo indicación contraria. ^a Valores presentados en el orden Botnet/WebAttack. ^b El estudio reporta $AUPR_{OUT}$, equivalente a AUPR con las muestras desconocidas como clase positiva. NR: no reportado.

próxima en términos de conjunto de datos y familia OOD. En el escenario B-3, CICIDS2018 se organiza en seis categorías totales: Benign, DoS, DDoS, Bot, Infiltration y Bruteforce. Bot se excluye completamente del entrenamiento, por lo que el sistema se ajusta con cinco clases conocidas y evalúa posteriormente la familia retenida como amenaza de día cero. El mecanismo combina un VAE, distancia de Mahalanobis y calibración robusta basada en MAD. Los autores reportan métricas dependientes del punto operativo para Bot, pero no proporcionan AUROC ni AUPR, por lo que el estudio se utiliza principalmente como referencia metodológica y no como comparación directa de la capacidad global de separación. Además, su análisis muestra que Bot puede presentar solapamiento parcial con tráfico no-zero-day en el espacio de Mahalanobis, lo que evidencia la dificultad de separar esta familia cuando sus patrones se aproximan a regiones conocidas.

Zhang et al. [20] presentan una mayor proximidad en la formulación geométrica y en la evaluación de Botnet y WebAttack. Su enfoque

proyecta características de flujo en una representación bidimensional, aprende un espacio latente mediante una CNN y aplica una decisión basada en la distancia al centroide conocido más cercano. Para CICIDS2017, los autores utilizan cinco clases conocidas y reservan diferentes familias para validación y prueba. Botnet y WebAttack se evalúan individualmente, alcanzando valores de AUROC de 0,9740 y 0,9240, junto con valores de $AUPR_{OUT}$ de 0,9660 y 0,9260, respectivamente. En OSR-ViT, por el contrario, Botnet y Web_Attack se evalúan conjuntamente sobre CSE-CIC-IDS2018. En consecuencia, las métricas describen configuraciones OOD distintas y no deben interpretarse como resultados obtenidos sobre una misma tarea.

Talpini et al. [16] evaluaron una red neuronal bayesiana sobre flujos tabulares de CICIDS2017 y definieron diferentes escenarios con múltiples clases desconocidas. Las clases OOD se excluyen completamente del entrenamiento, se equilibran para la evaluación y se analizan conjuntamente. El umbral de distancia se calibra mediante el percentil 99,5 de las distancias obtenidas sobre el conjunto

de validación. El AUROC de $0,7300 \pm 0,0300$ corresponde al promedio de varios escenarios y no al desempeño de una familia individual. El estudio también reporta la métrica restringida $AUROC_{20}^* = 0,3900 \pm 0,0200$, orientada a evaluar la separación en una región con una tasa limitada de falsos rechazos conocidos; sin embargo, esta medida no es equivalente a AUPR OOD y, por tanto, no se incorpora como una columna adicional.

En conjunto, los estudios revisados muestran que la evaluación de amenazas no observadas depende de la composición de las clases conocidas, de la forma en que se aíslan las familias OOD, del procedimiento de calibración y de la representación utilizada. OSR-ViT comparte con Park y Lim el uso de CSE-CIC-IDS2018, la retención de Botnet como familia OOD y la calibración robusta; con Zhang et al., el aprendizaje de representaciones visuales y la decisión geométrica en el espacio latente; y con Talpini et al., la separación estricta entre calibración y prueba. Estas coincidencias permiten situar metodológicamente la propuesta dentro de la literatura reciente, aunque las diferencias de dataset, unidad de análisis, composición OOD y métricas impiden establecer conclusiones directas de superioridad cuantitativa entre los modelos.

6. Conclusiones, limitaciones y trabajo futuro

Este estudio evaluó la integración de aprendizaje visual y reconocimiento de conjunto abierto para la detección de amenazas no observadas en tráfico de red. OSR-ViT alcanzó una Accuracy de 0,9995, un Macro F1 de 0,9989 y un MCC de 0,9986 sobre las clases conocidas. En la evaluación abierta, bajo el punto operativo seleccionado, se obtuvo un AUROC de 0,8280, un AUPR de 0,7474, un $Recall_{OOD}$ de 0,6836, un $F1_{OOD}$ de 0,7511 y una FRR_{Known} de 0,1933. Estos resultados muestran que la detección OOD debe analizarse conjuntamente con el falso rechazo inducido sobre el dominio conocido.

El principal aporte del trabajo consiste en combinar una representación derivada de paquetes, un *Vision Transformer* y una regla geométrica

de rechazo calibrada exclusivamente con datos conocidos. No obstante, las conclusiones están condicionadas por el uso de CSE-CIC-IDS2018, una configuración fija de $N_{min} = 7$ y una distribución OOD dominada por Botnet, por lo que los resultados deben interpretarse dentro del protocolo experimental definido.

6.1. Limitaciones del estudio

El diseño experimental presenta limitaciones asociadas al alcance temporal de la representación, a la selección de familias evaluadas y al punto operativo del mecanismo OSR. En primer lugar, la restricción de la ventana de observación al umbral estricto de $N_{min} = 7$ paquetes introduce un sesgo de selección. Al descartar las conexiones con menos de siete paquetes y truncar las restantes a este límite exacto, la arquitectura reduce la cantidad de información requerida antes de emitir una decisión; sin embargo, excluye del análisis a los vectores de ataque de muy corta duración (como ciertas ráfagas de escaneo de puerto o inyecciones de un solo paquete) y puede limitar la detección de amenazas cuyo comportamiento malicioso se manifiesta en etapas muy posteriores del intercambio de la conexión.

En segundo lugar, la evaluación de reconocimiento abierto se restringe a una separación determinista específica del conjunto CSE-CIC-IDS2018. Las clases conocidas se limitan a tráfico benigno, DoS y DDoS, mientras que Botnet y Web_Attack se aíslan como familias OOD. Esta decisión permite evaluar el rechazo de amenazas no observadas bajo un protocolo controlado, pero no garantiza que el mismo comportamiento se mantenga frente a todas las familias de ataque disponibles en el conjunto de datos ni frente a otros entornos de red.

En tercer lugar, el escudo OSR basado en distancia latente introduce un compromiso entre sensibilidad ante muestras OOD y preservación del tráfico conocido. Valores más estrictos del umbral pueden incrementar la detección de amenazas no vistas, pero también elevar el rechazo de muestras conocidas. Por ello, los resultados deben interpretarse como el desempeño de un punto operativo específico del mecanismo de

rechazo, no como una eliminación completa del riesgo de falsos rechazos o falsas aceptaciones en escenarios de día cero.

Finalmente, el diseño experimental de este estudio se delimitó a validar la viabilidad y eficacia de la arquitectura OSR-ViT como un flujo de procesamiento integral y cohesivo (End-to-End). Por consiguiente, el presente manuscrito no incluye un estudio de ablación exhaustivo que aísle y cuantifique la contribución empírica individual de cada uno de sus componentes matemáticos y estructurales (tales como la pérdida Focal frente a la regularización de Fisher, el impacto aislado de la transformación por cuantiles o la comparación entre umbrales globales y específicos por clase). El análisis granular de la varianza introducida por cada módulo y la optimización independiente de estos hiperparámetros se establecen como una limitación del alcance actual y como la principal línea de trabajo futuro para el refinamiento de la arquitectura.

6.2. Trabajo futuro

Como trabajo futuro, se propone evaluar la arquitectura en otros datasets y mediante protocolos inter-dataset que permitan estudiar cambios de dominio, deriva temporal y diferentes composiciones de clases desconocidas. También será necesario analizar otros tamaños de ventana, ejecutar estudios de ablación sobre RGB-E, la regularización de Fisher, PCA, la transformación cuantílica y la calibración MAD, y repetir los experimentos con múltiples semillas e intervalos de confianza.

Finalmente, deberá investigarse el diseño de mecanismos de aceptación que mejoren el equilibrio entre falso rechazo conocido y recuperación OOD. Esta línea incluye umbrales adaptativos por clase, actualización controlada de centroides, adaptación ante deriva conceptual y aprendizaje incremental para incorporar nuevas categorías sin degradar el conocimiento previamente adquirido. Asimismo, la viabilidad operativa deberá evaluarse mediante métricas de latencia, consumo de memoria, utilización de recursos y capacidad de procesamiento en línea.

Agradecimientos

Los autores agradecen a la Dra. Consuelo Negrón Martínez por la revisión final del manuscrito y por sus comentarios orientados a mejorar la claridad, consistencia y presentación del artículo.

Contribuciones de los autores

Luis J. Villegas: conceptualización, diseño metodológico, desarrollo de software, validación, visualización, elaboración de figuras y tablas, administración del proyecto, y revisión y edición del manuscrito.

Emerson A. Espinoza: curación y procesamiento de datos, investigación, ejecución de experimentos, análisis formal, interpretación de resultados, redacción del borrador original, y revisión y edición del manuscrito.

Yury O. Tello: supervisión académica, asesoramiento metodológico y revisión crítica del manuscrito.

Los autores asumen la responsabilidad por el contenido y los resultados presentados en el trabajo.

Declaración sobre el uso de inteligencia artificial

Durante la preparación de este trabajo, los autores utilizaron herramientas de inteligencia artificial generativa, específicamente NotebookLM y ChatGPT, exclusivamente como apoyo editorial para mejorar la redacción, claridad y expresión lingüística del manuscrito. Estas herramientas no fueron empleadas para generar los datos experimentales, las métricas, la interpretación de los resultados ni las conclusiones científicas. Su uso tampoco sustituyó el análisis crítico realizado por los autores. Todo el contenido asistido por estas tecnologías fue revisado, corregido y validado por los autores, quienes asumen plena responsabilidad por la versión final de la publicación.

Disponibilidad de datos y código fuente

El conjunto de datos CSE-CIC-IDS2018 utilizado en este estudio se encuentra disponible públicamente a través del Canadian Institute for Cybersecurity de la University of New Brunswick:

<https://www.unb.ca/cic/datasets/ids-2018.html>.

El código fuente desarrollado para la construcción de las sesiones RGB-E, el entrenamiento del modelo OSR-ViT y la evaluación experimental, junto con los archivos de configuración y los scripts asociados, se encuentra disponible en el siguiente repositorio público:

https://github.com/LuisVillegasCode/proyecto_ids_vit.git.

Las capturas PCAP originales no se redistribuyen mediante el repositorio debido a su tamaño.

Referencias

1. **Alsalamah, H. A., Ismail, W. N. (2025).** Evolutionary computation for feature optimization and image-based dimensionality reduction in iot intrusion detection. *Mathematics*, Vol. 13, No. 23. DOI: 10.3390/math13233869.
2. **Alzughairi, S., El Khediri, S. (2023).** A cloud intrusion detection systems based on dnn using backpropagation and pso on the cse-cic-ids2018 dataset. *Applied Sciences (Switzerland)*, Vol. 13, No. 4. DOI: 10.3390/app13042276.
3. **Baye, G., Silva, P., Broggi, A., Bastian, N. D., Fiondella, L., Kul, G. (2024).** varmax: Towards confidence-based zero-day attack recognition. pp. 863 – 868. DOI: 10.1109/MILCOM61039.2024.10773707.
4. **Berrios Vasquez, S. I., Hermosilla Monckton, P. A., Leiva Muñoz, D. I., Allende, H. (2025).** Zero-day threat mitigation via deep learning in cloud environments. *Applied Sciences (Switzerland)*, Vol. 15, No. 14. DOI: 10.3390/app15147885.
5. **Chicco, D., Jurman, G. (2020).** The advantages of the matthews correlation coefficient (mcc) over f1 score and accuracy in binary classification evaluation. *BMC Genomics*, Vol. 21, No. 1. DOI: 10.1186/s12864-019-6413-7.
6. **Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., Houlsby, N. (2021).** An image is worth 16x16 words: Transformers for image recognition at scale.
7. **Ghadermazi, J., Shah, A., Bastian, N. D. (2025).** Towards real-time network intrusion detection with image-based sequential packets representation. *IEEE Transactions on Big Data*, Vol. 11, No. 1, pp. 157 – 173. DOI: 10.1109/TBDATA.2024.3403394.
8. **He, K., Zhang, W., Zong, X., Lian, L. (2024).** Network intrusion detection based on feature image and deformable vision transformer classification. *IEEE Access*, Vol. 12, pp. 44335 – 44350. DOI: 10.1109/ACCESS.2024.3376434.
9. **Ho, C. M. K., Yow, K.-C., Zhu, Z., Aravamuthan, S. (2022).** Network intrusion detection via flow-to-image conversion and vision transformer classification. *IEEE Access*, Vol. 10, pp. 97780 – 97793. DOI: 10.1109/ACCESS.2022.3200034.
10. **Kamal, H. (2024).** Advanced hybrid transformer-cnn deep learning model for effective intrusion detection systems with class imbalance mitigation using resampling techniques. *Future Internet*, Vol. 16, No. 12. DOI: 10.3390/fi16120481.
11. **Kumar, K. P., Kumar, D. N. S. (2025).** Advanced attack mitigation in iot gateway protocols. *Computers and Security*, Vol. 157. DOI: 10.1016/j.cose.2025.104539.
12. **Mahendar, K., Shivakanth, G. (2025).** A performance analysis of ml-based intrusion detection systems in cloud environments. *International Journal of Electrical and Electronic Engineering and Telecommunications*, Vol. 14, No. 4, pp. 243 – 252. DOI: 10.18178/ijeetc.14.4.243-252.

13. **Nitrat, K., Suetrong, N., Promsuk, N. (2025).** Zero-day attack detection in iot networks using a residual vision transformer-based approach with zero-shot learning. IEEE Open Journal of the Communications Society, Vol. 6, pp. 7405 – 7423. DOI: 10.1109/OJCOMS.2025.3604826.
14. **Park, Y.-S., Lim, Y.-S. (2026).** Hybrid multi-stage framework for identifying zero-day attacks and known threats in network traffic. Computer Networks, Vol. 275. DOI: 10.1016/j.comnet.2025.111875.
15. **Sakthivel, G., Kumarasamy, A. K. (2026).** A drift-aware rs2fs pipeline with confidence gating for ids. Scientific reports, Vol. 16, No. 1, pp. 4029. DOI: 10.1038/s41598-025-34124-x.
16. **Talpini, J., Sartori, F., Savi, M. (2024).** Enhancing trustworthiness in ml-based network intrusion detection with uncertainty quantification. Journal of Reliable Intelligent Environments, Vol. 10, No. 4, pp. 501 – 520. DOI: 10.1007/s40860-024-00238-8.
17. **Vij, A., Tran, H.-A., Tran, T. X. (2024).** Trustable network intrusion detection system through wisdomnet and uncertainty measures. DOI: 10.1109/LCN60385.2024.10639737.
18. **Wang, C., Zhang, J. (2024).** Study on open set based intrusion detection method;. Computer Science, Vol. 51, No. 11 A. DOI: 10.11896/jsjkkx.231000033.
19. **Yang, B., Arshad, M. H., Zhao, Q. (2022).** Packet-level and flow-level network intrusion detection based on reinforcement learning and adversarial training.. Algorithms, Vol. 15, No. 12, pp. 453–null.
20. **Zhang, Z., Zhang, Y., Guo, D., Song, M. (2021).** A scalable network intrusion detection system towards detecting, discovering, and learning unknown attacks. International Journal of Machine Learning and Cybernetics, Vol. 12, No. 6, pp. 1649 – 1665. DOI: 10.1007/s13042-020-01264-7.
21. **Zhou, H., Zou, H., Li, W., Li, D., Kuang, Y. (2025).** Hivit-ids: An efficient network intrusion

detection method based on vision transformer. Sensors, Vol. 25, No. 6. DOI: 10.3390/s25061752.

**Corresponding author is L. J. Villegas.*